基于稀疏双注意力强化学习的多无人机协同覆盖方法

陈向伟，杨健，张立东

***Abstract*—**本文研究了动态环境中多无人机（multi-UAV）协同覆盖问题，旨在实时最大化目标覆盖范围并规避障碍物。现有方法在复杂覆盖任务的实时决策中常面临困难，且适应性有限。为解决这一问题，我们提出一种结合动态稀疏激活的双注意力机制，并将其集成到集中训练与分散执行（CTDE）的多智能体深度强化学习（MADRL）框架中。我们的方法分层处理包含目标、障碍物及邻近无人机的观测集，同时通过动态稀疏激活提升训练过程中关键特征学习的准确性与效率。该机制使智能体能够有选择地关注关键环境线索，减少冗余计算，从而提升实时多无人机协同决策能力。此外，为增强无人机间的协同行为，为每架无人机设计了交互注意力机制，使其能够通过信息交换协调覆盖策略。实验结果表明，我们的方法在复杂覆盖任务中优于现有方法，并在大规模无人机协同场景中展现出强大的可扩展性。

***Index Terms*—**双注意力机制、多目标覆盖、深度强化学习。

一、引言

无人飞行器（UAVs）具有多种显著优势，包括长续航能力、高灵活性、紧凑尺寸和成本效益[1]，[2]。与单UAV系统相比，多UAV系统在大规模部署场景中展现出更强的容错性和操作可靠性[3]。这些优势显著提升任务连续性和执行稳定性，使多无人机系统特别适用于在动态环境中执行复杂任务，如搜救行动、环境监测、野火响应和城市监控[4]，[5]。它们在低空城市反无人机（CUAV）任务中也具有潜力，可用于探测并中和威胁其他无人机和地面资产的恶意无人机[6]。

在多无人机应用中，无人机必须快速抵达关键区域以应对紧急事件[7]，这可表述为实时多目标覆盖任务[8]。无人机持续监测环境，动态分配目标，并基于实时数据进行导航，旨在最小化重叠、最大化覆盖范围，并迅速响应威胁。在有限的观测范围内，无人机需识别关键特征，优先安排覆盖任务，并与邻近无人机协同，以实现有效的多目标覆盖。基于预计算全局规划的传统集中式方法在动态场景中往往失效。分布式方法通过局部感知和自主决策提升了实时响应能力，但其对预设协调规则的依赖以及缺乏数据驱动的学习能力，可能导致在复杂多目标覆盖任务中出现资源冲突和效率低下。

近年来，多智能体深度强化学习（MADRL）已成为处理复杂多智能体任务的有效方法。在集中训练与分散执行（CTDE）范式[9]，[10]下，智能体在训练期间共享观测信息，但在执行时仅基于局部观测进行决策。在协同多无人机任务中，智能体必须同时考虑实体间的几何关系与其他无人机的协调策略。因此，多项研究将MADRL与注意力机制[11]，[12]、Transformer[13]、图神经网络（GNNs）[14]、图注意力网络（GATs）[15]，[16]、卷积神经网络（CNNs）[17]，[18]等技术相结合。这些方法有效捕捉了实体间的时空关系与智能体间的社会交互，提升了区域覆盖、目标搜索与跟踪等任务中的决策准确性与适应性。利用智能体间通信[19]，[20]和预测建模[21]的方法进一步补充了局部观测，为我们的工作提供了有价值的参考。

然而，在复杂和动态的环境中，冗余观测会负面影响学习效率。从观测中提取关键信息至关重要。一些研究使用注意力机制来评估信息的时间或空间重要性以及智能体间的交互[22]，[23]，[24]。然而，它们缺乏显式的冗余

2025年4月20日收到；2026年1月11日接受。发表日期为2026年2月12日；当前版本日期为2026年2月19日。本文经审稿人意见评估后，由副编辑E. B y k和编辑A. Faust推荐发表。本工作部分受到国家自然科学基金（项目编号：62476098）、广东省基础与应用基础研究基金（项目编号：2024A1515030177）、中国航空科学基金（项目编号：20240055060001）以及中央高校基本科研业务费（项目编号：2024ZYGXZR061）的支持。*(Corresponding author: Jian Yang.)*

陈向伟和杨健位于中国广东省广州市华南理工大学自动化科学与工程学院，邮编510641，同时隶属于教育部自主系统与网络控制重点实验室，广州市，广东省，510641，中国（电子邮件：csu_cxw@163.com；yangjianxin@scut.edu.cn）。

张立东就职于中国民用航空局航空电子技术实验室（上海 200241，中国），同时就职于中国航空无线电电子研究所（上海 200241，中国）（邮箱：zhang_lidong@careri.com）。

数字对象标识符 10.1109/LRA.2026.3664265

2377-3766 © 2026 IEEE. All rights reserved, including rights for text and data mining, and training of artificial intelligence and similar technologies. Personal use is permitted, but republication/redistribution requires IEEE permission. See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

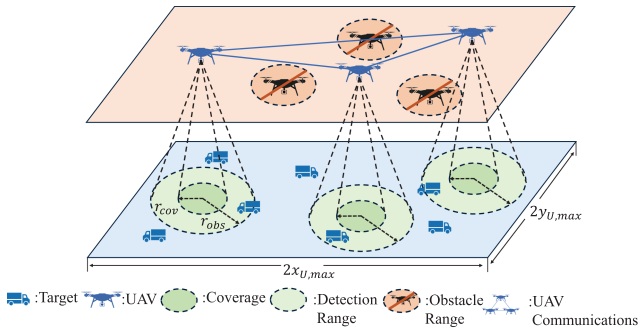

图1. 涉及动态目标和障碍区域的协同多无人机覆盖场景。

抑制，导致高维且计算成本高昂的状态表示，可能损害决策能力。

因此，我们提出了一种具有动态稀疏激活的双注意力方法。每个智能体的局部观测被划分为目标、障碍物和邻近无人机。实体注意力模块（EAM）从每组中提取关键信息，而动态稀疏激活逐步过滤冗余数据。交互注意力模块（IAM）强调来自邻近无人机的关键观测，以增强协作。所提出的方法在不同复杂度的多目标覆盖仿真中得到了验证。

本工作的主要贡献如下：

- 我们提出了一种基于MADRL的双注意力学习方法。在EAM中，实体被分为三类，并设计了分层注意力机制以从每类中提取关键信息。• 我们引入了一种动态稀疏激活机制，以有效过滤冗余信息。为避免丢失关键信息并确保对冗余信息的恰当过滤，设计了动态稀疏调节参数以提升训练效率。• 我们构建了一个仿真环境来验证我们的方法。实验结果表明，在实体数量变化的场景中，我们的方法优于现有方法。

其余部分组织如下：第二节建立系统模型和任务目标；第三节提出基于MADRL的稀疏双注意力框架；第四节通过仿真评估所提算法；第五节给出结论与未来工作。

二、系统模型与问题表述

A. Problem Statement

在本文中，我们将在由N个同构无人机$\mathbf{U}=\{1,\ldots,N\}$、$M$个目标$\mathbf{G}=\{1,\ldots,M\}$和$K$个障碍区域$\mathbf{T}=\{1,\ldots,K\}$组成的二维环境中，对多目标覆盖问题进行建模，这些统称为实体$\mathbf{E}=\{\mathbf{U},\mathbf{G},\mathbf{T}\}$。如图1所示，每个任务开始时，所有实体的位置均随机初始化。所有无人机具有相同的飞行能力，具有固定的观测半径R_{obs}和覆盖半径R_{cov}。系统目标是在有限的时间范围内最大化目标覆盖范围，同时确保避碰。

B. System Model

我们考虑一个由N架无人机、M个目标和K个障碍物组成的动态环境。无人机编号为$i\in\{1,2,\ldots,N\}$。在时间步t，无人机U_i的位置记为$P_i^t=(x_i^t,y_i^t)$。在时间t，U_i的速度和航向角分别表示为v_i^t和θ_i^t。U_i的运动学描述如下：

$$\begin{cases} x_i^t = x_i^{t-1} + v_i^{t-1}\cos\theta_i^{t-1}\Delta t & -x_{max}\le x_i^t\le x_{max} \\ y_i^t = y_i^{t-1} + v_i^{t-1}\sin\theta_i^{t-1}\Delta t & -y_{max}\le y_i^t\le y_{max} \\ v_i^t = v_i^{t-1} + a_i^{t-1}\Delta t & -v_{max}\le v_i^t\le v_{max} \end{cases} \tag{1}$$

每架无人机监测其传感器范围内的实体。U_i的观测指示函数定义如下：

$$\mathbb{I}_{\text{obs}}(U_i,E_j,t)=\begin{cases}1 & \text{if } \|P_i^t-P_j^t\|\le R_{\text{obs}},\\ 0 & \text{else.}\end{cases} \tag{2}$$

$\mathbb{I}_{obs}(U_i,E_j,t)=1$ 表示 U_i 检测到实体 E_j。类似地，覆盖率指示函数定义为：

$$\mathbb{I}_{cov}(U_i,G_m,t)=\begin{cases}1 & \text{if } \|P_i^t-P_m^t\|\le R_{cov}\\ 0 & \text{else}\end{cases} \tag{3}$$

$\mathbb{I}_{cov}(U_i,G_m,t)$ 描述当 U_i 与 G_m 之间的距离小于 R_{cov} 时，U_i 完成目标覆盖任务。目标是最大化随时间累积的目标覆盖量：

$$J=\sum_{i=1}^{N}\sum_{t=0}^{T}\mathbb{I}_{cov}(U_i,G_m,t) \tag{4}$$

为避免碰撞，无人机必须与其他无人机和障碍物保持安全距离。设 R_{safe}^1 表示无人机之间的最小安全距离，R_{safe}^2 表示无人机与障碍物边界之间的最小安全距离。无人机必须满足以下约束：

$$\begin{cases}\|P_i^t-P_j^t\|\ge R_{safe}^1 & \forall U_i,U_j\in U, i\ne j\\ \|P_i^t-P_k^t\|\ge R_{safe}^2 & \forall U_i\in U,\forall T_k\in T\end{cases} \tag{5}$$

C. Problem Transformation

协作多无人机目标覆盖任务被建模为去中心化部分可观测马尔可夫决策过程（Dec-POMDP），由元组 $\langle N,S,O,A,P,R,\gamma\rangle$ 定义，其中 N 表示无人机数量。全局状态为 $s\in S=\mathbb{R}^{N\times D}$，$D$ 表示状态维度。每架无人机 U_i 接收局部观测 $o_i=O(s)\in\mathbb{R}^d$，其中 $d<D$。无人机 U_i 的动作是 $a_i\in A$，所有无人机的联合动作记为 $\mathbf{a}=(a_1,\ldots,a_N)$。状态转移动力学由 $P(s'\mid s,\mathbf{a})$ 控制。所有无人机共享一个公共奖励函数 $r:S\times A\to\mathbb{R}$，γ 为折扣因子。每架无人机遵循去中心化策略 $\pi_i^\theta(a_i\mid o_i)$，旨在最大化期望折扣回报 $G_t=\sum_{k=0}^{\infty}\gamma^k r_{t+k}$。

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

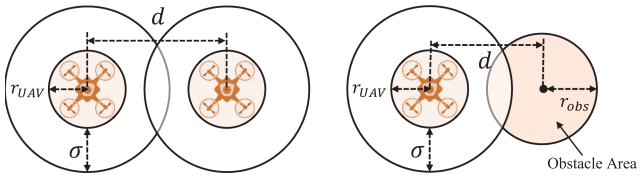

图2. 无人机之间以及无人机与障碍物之间的冲突威胁区。

Observation Space: 在时间 t 对 U_i 的观测 o_i^t 包含四个部分：1) U_i 自身的状态，记为 $[P_i^t, v_i^t]$，其中 $P_i^t = (x_i^t, y_i^t)$ 和 $v_i^t = (v_i^{x,t}, v_i^{y,t})$ 分别表示 U_i 的位置和速度；2) 其他无人机的相对状态信息记为 $[P_j^t - P_i^t, v_j^t - v_i^t]$，对应 $j \le N$ 和 $j \ne i$；3) 目标 G_m 的相对状态信息记为 $[P_m^t - P_i^t]$，其中 $m \le M$；4) 所有障碍物 T_k 的相对状态信息记为 $[P_k^t - P_i^t, r_k]$，其中 $k \le K$ 和 r_k 表示障碍物 T_k 的半径。对于超出 U_i 观测范围的实体，其相对信息将设为零向量。

Action Space: U_i 的作用由 x 方向和 y 方向的加速度组成，记为 $a_i^t = (a_i^{t,x}, a_i^{t,y})$，其中 $a_i^{t,x}$ 和 $a_i^{t,y} \in [-a_{max}, a_{max}]$。策略 $\pi_i^\theta(a_i|o_i)$ 输出归一化的动作，范围为 $[-1, 1]$，并通过 a_{max} 缩放以获得实际值。

Reward Function: 奖励函数分解为两个关键组成部分：碰撞惩罚和覆盖奖励。

1) Collision Penalty: 如图2所示，我们为每架无人机定义一个宽度为σ的威胁区域。若两架无人机之间的距离d小于$2r_{UAV} + \sigma$，则存在潜在碰撞风险。我们定义碰撞风险惩罚函数如下：

$$r_1 = \begin{cases} -\frac{0.02}{e^{d-2r_{UAV}}} & 2r_{UAV} < d < 2r_{UAV} + \sigma \\ -50 & 0 \le d \le 2r_{UAV} \\ 0 & \text{else} \end{cases} \tag{6}$$

类似地，无人机接近障碍物的惩罚函数定义如下：

$$r_2 = \begin{cases} -\frac{0.02}{e^{d-D}} & D < d < D + \sigma \\ -50 & 0 \le d \le D \\ 0 & \text{else} \end{cases} \tag{7}$$

其中 $D = r_{UAV} + r_{obs}$。

2) Coverage Reward: 每架无人机成功覆盖目标可获得10个奖励单位，记为$r_3 = 10$。

总之，每个无人机的总体奖励函数可表示为：

$$R_{UAV} = r_1 + r_2 + r_3 \tag{8}$$

III. 所提出的算法

A. Overall Framework

我们的方法框架如图3所示，该方法基于CTDE范式。

在集中训练期间，评论家网络结合了基于多头的交互注意力模块（IAM）多头注意力（MHA）用于有选择地关注其他智能体的观测，从而提取与目标智能体最相关的交互信息。在演员网络和评论家网络中，实体注意力模块（EAM）将实体分为三类，并应用三层自注意力结构来捕捉每类中的显著特征。此外，引入了一种动态稀疏激活机制，以稀疏化注意力权重，有效过滤冗余信息。在去中心化执行过程中，评论家网络被移除，每个智能体仅依赖其演员网络，利用局部观测生成动作以实现自主决策。

B. Entity Attention Module (EAM)

对于每个智能体 i，观测-动作对 (o_i, a_i) 根据不同的实体集合分解为四个部分：1) 自身状态-动作对 (o_i^{own}, a_i)，包含智能体 i 的位置、速度和动作信息；2) 目标状态信息 o_i^{goal}，包含目标的相对位置；3) 队友状态信息 o_i^{ally}，包含其他智能体的相对位置和速度；4) 障碍物状态信息 $o_i^{obstacle}$，包含障碍物的相对位置和半径。在 EAM 中，(o_i^{own}, a_i) 作为查询，而 o_i^{goal}、o_i^{ally} 和 o_i^{obstacle} 作为键和值，其相关性通过缩放点积注意力进行度量。

$$\text{score}_i^{\text{entity}_j} = \frac{\left(o_i^{\text{entity}_j}\right)^T W_{\text{entity},k} W_{\text{own},q}(o_i^{\text{own}}, a_i)}{\sqrt{d_{\text{EAM}}}} \tag{9}$$

其中实体 $\in$ [盟友, 目标, 障碍] 且 d_{EAM} 表示 $W_{\text{entity},k}$ 的维度。随后，通过激活函数将计算出的相似度归一化为概率分布。尽管 Softmax 常用于此目的，但其本质上是非稀疏的，会为所有实体分配非零注意力权重，无论其相关性如何。在许多观测实体重要性可忽略的场景中，这一特性并不理想，可能导致信息冗余。为解决此问题，我们引入了一种稀疏激活函数，使智能体能够通过为不重要的实体分配零注意力权重，从而聚焦于最相关的实体。

稀疏激活函数 [25] 定义如下：

$$\text{sparsemax}(z) := \arg\min_{\boldsymbol{p} \in \Delta^d} \|\boldsymbol{p} - \boldsymbol{z}\|^2 \tag{10}$$

其中 Δ^d 表示 d 维概率单纯形，定义为 $\Delta^d := \{p \in \mathbb{R}^d : p \ge 0, \|p\|_1 = 1\}$。通过对输入向量 $\boldsymbol{z}$ 进行降序排序并应用拉格朗日方法，Sparsemax 函数的解推导如下：

$$\text{Sparsemax}_i(\boldsymbol{z}) = [z_i - \tau(\boldsymbol{z})]_+ \tag{11}$$

$$\text{s.t.} \quad \sum_j [z_j - \tau(\boldsymbol{z})]_+ = 1 \tag{12}$$

$$\tau(\boldsymbol{z}) = \frac{\left(\sum_{j \le k(\boldsymbol{z})} z_{(j)} - 1\right)}{k(\boldsymbol{z})} \tag{13}$$

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

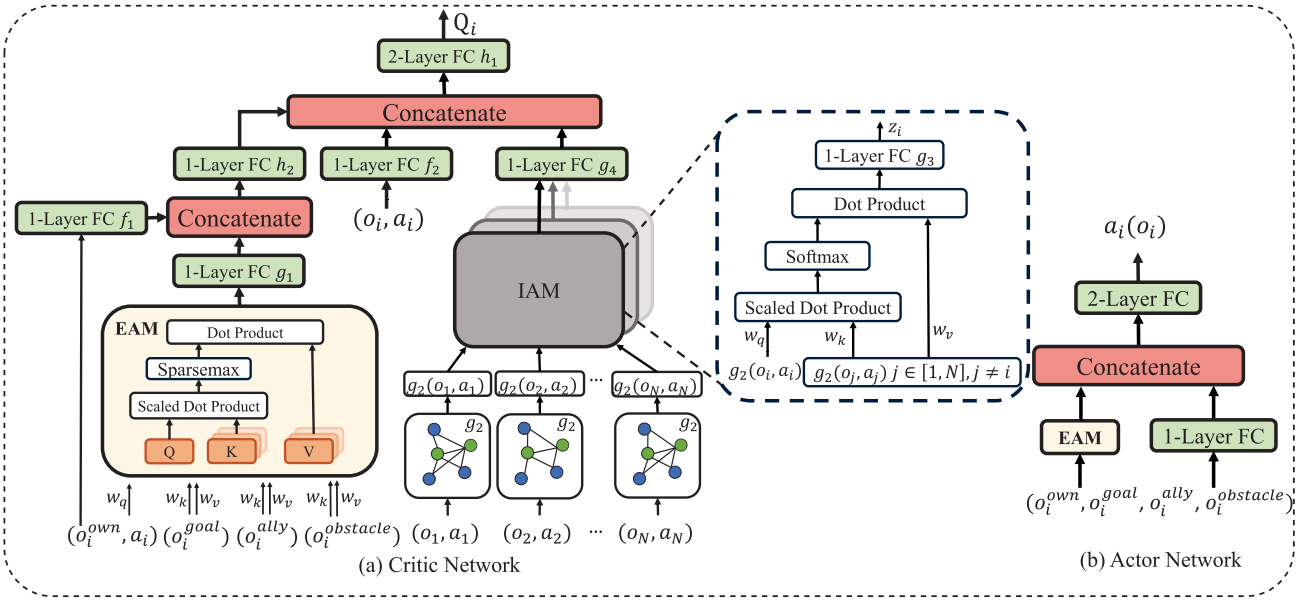

图3. 稀疏双注意力多智能体双延迟深度确定性策略梯度（SDA-MATD3）的整体框架。（a）智能体i的评论家网络，其中EAM表示实体注意力模块，IAM表示交互注意力模块。（b）智能体i的演员网络。

$$k(\boldsymbol{z}) := \max\left\{k \in [K] \mid 1 + kz_{(K)} > \sum_{j \le k} z_{(j)}\right\} \tag{14}$$

其中 $k(\boldsymbol{z})$ 表示解中非零元素的个数，$[\cdot]_+ = \max\{0, \cdot\}$。$\tau(\boldsymbol{z})$ 表示 $\boldsymbol{z}$ 的阈值函数，使得当概率 z_j 小于 $\tau(\boldsymbol{z})$ 时，z_j 被设为零。

然而，在训练初期应用Sparsemax函数可能由于其强稀疏性而错误地抑制关键实体，因为智能体尚未学会不同观测值的相对重要性，这可能会阻碍训练。为缓解这一问题，我们引入了一种动态稀疏度调整机制，以在训练过程中逐步调节稀疏度水平。具体而言，在训练初期采用Softmax函数，使EAM能够从更广泛的实体信息中学习。随着训练的进行，逐步引入Sparsemax函数以强制稀疏性，确保在EAM学会聚焦关键信息后，仅过滤非关键实体。引入了一个稀疏度控制参数λ来管理这一过渡过程，并在训练过程中线性增加。智能体i在其观测范围内对实体j的注意力权重定义为：

$$w_i^{\text{entity}_j} = \lambda \cdot \text{sparsemax}\left(\text{score}_i^{\text{entity}_j}\right) + (1-\lambda) \cdot \text{softmax}\left(\text{score}_i^{\text{entity}_j}\right) \tag{15}$$

随后，对于每个实体集，注意力权重 $w_i^{\text{entity}_j}$ 与对应的值向量 $v_i^{\text{entity}_j}$ 相乘，得到注意力值 z_i^{entity}。这些来自不同实体集的注意力值随后被连接起来。EAM 的最终输出通过全连接层获得，记为 g_1。

$$\text{att}_i^{\text{EAM}} = g_1\left(\text{concat}(z_i^{\text{entity}})\right) \tag{16}$$

$$z_i^{\text{entity}} = \sum_{j \in [1,M]} w_i^{\text{entity}_j} v_i^{\text{entity}_j} \tag{17}$$

类似地，EAM 被应用于演员网络。由于演员不将动作信息作为输入，因此使用 o_i^{own} 作为查询，其余实现步骤与评论家网络相同。

C. Interaction Attention Module (IAM)

在集中训练期间，对于每个智能体 i，IAM 将 (o_j, a_j)，$j \in [1, N]$ 输入到一个由全连接层组成的编码器 g_2 中，以生成每个观测-动作对的嵌入 $g_2(o_j, a_j)$。IAM 利用参数矩阵 W_q 基于 $g_2(o_i, a_i)$ 生成查询，并使用 W_k 和 W_v 从 $g_2(o_j, a_j), j \neq i$ 生成键和值。智能体 i 的嵌入与其他智能体的嵌入之间的相似性通过缩放点积计算，并通过 Softmax 函数归一化：

$$\text{score}_{i,j} = \frac{g_2(o_j, a_j)^T W_k^T W_q g_2(o_i, a_i)}{\sqrt{d_{IAM}}} \tag{18}$$

$$w_{i,j} = \frac{\exp(\text{score}_{i,j})}{\sum_{k \in [1,N], k \neq i} \exp(\text{score}_{i,k})} \tag{19}$$

代理 i、$w_{i,j}$、$j \in [1, N]$、$j \neq i$ 的注意力权重与对应的值向量（排除代理 i）v_j、$j \in [1, N]$、$j \neq i$ 相乘，以获得代理 i 的注意力值。这些注意力值随后通过一个全连接

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

将层 g_3 转换为 z_i:

$$z_i = g_3\left(\sum_{j\in[1,N],j\neq i} w_{i,j} v_j\right) \tag{20}$$

其中 $v_j = W_v g_2(o_j, a_j)$。IAM 的输出 $[z_1, \ldots, z_N]$ 被连接并通过另一个全连接层 g_4 以获得最终输出:

$$\text{att}_i = g_4\left(\text{concat}(z_k, k \in [1, N])\right) \tag{21}$$

最后，在双注意力机制下，代理 i 的集中式 Q 函数表示为:

$$Q_i = h_1\left(h_2\left(f_1(o_i^{\text{own}}, a_i), \text{att}_i^{EAM}\right), f_2(o_i, a_i), \text{att}_i\right) \tag{22}$$

D. Training Algorithm

我们的方法基于多智能体双延迟深度确定性策略梯度（MATD3）算法实现，该算法是多智能体深度确定性策略梯度（MADDPG）[26] 算法的优化版本。

评论网络通过聚合所有无人机的观测-动作信息来估计Q值。基于时间差分（TD）误差，参数为$\theta_{i,j}$的评论网络的损失函数定义为:

$$\mathcal{L}(\theta_{i,j}) = \frac{1}{B}\sum_{k=1}^{B}\left[\left(Q_{i,j}(\mathbf{o}^k, \mathbf{a}^k; \theta_{i,j}) - y_{i,j}^k\right)^2\right] \tag{23}$$

$$y_{i,j} = r_i + \gamma \min_{j=1,2} Q'_{i,j}\left(\mathbf{o}', \mathbf{a}'; \theta'_{i,j}\right)\Big|_{\mathbf{a}'=\boldsymbol{\mu}'_{\boldsymbol{\varphi}'}(\mathbf{o}')+\boldsymbol{\epsilon}} \tag{24}$$

演员网络通过最大化评论家网络估计的Q值来选择最优动作。演员网络的梯度计算如下:

$$\nabla_{\varphi_i} J \approx \frac{1}{B}\sum_{k=1}^{B} \nabla_{\varphi}\mu_{\varphi_i}(o_i^k) \cdot \nabla_{a_i^k} Q_{i,1}(\mathbf{o}^k, \mathbf{a}^k; \theta_{i,j})\big|_{a_i^k=\mu_{\varphi_i}(o_i^k)} \tag{25}$$

其中，$\theta_{i,j}$ 和 $\theta'_{i,j}$ 分别表示第 j 个 ($j = 1, 2$) 评论网络和目标评论网络针对 U_i 的参数，φ_i 和 φ'_i 分别表示针对 U_i 的演员网络和目标演员网络的参数，$Q'_{i,j}$ 表示第 j 个目标评论网络针对 U_i 的 Q 值，$\mathbf{o}'$ 表示所有 UAV 在下一状态的局部观测，$\mathbf{a}'$ 表示目标演员网络为下一状态生成的动作，并添加了噪声。

目标网络通过软更新进行更新，如下所示:

$$\theta'_{i,j} \leftarrow \tau\theta_{i,j} + (1-\tau)\theta'_{i,j} \tag{26}$$

$$\varphi'_i \leftarrow \tau\varphi_i + (1-\tau)\varphi'_i \tag{27}$$

其中 $\tau \ll 1$。

训练算法详见算法1。

Algorithm 1: Training Algorithm for SDA-MATD3.

Initialize memory $\mathbf{D}$ and network parameters $\theta_{i,j}$, $\theta'_{i,j}$, φ_i, φ'_i, the actor network delay frequency f_a;
for $epoch \leftarrow 1, 2, \cdots$ **do**
  Reset the environment and receive the initial state observations $\mathbf{o} = (o_1, \ldots, o_N)$;
  for $timestep \leftarrow 1, 2, \cdots$ **do**
    Select and execute action $a_i = \mu_{\varphi_i}(o_i)$ based on the current actor network for each UAV;
    Receive rewards $\mathbf{r} = (r_1, \ldots, r_N)$ and next observations for each UAV $\mathbf{o}' = (o'_1, \ldots, o'_N)$;
    Store the transition $\langle \mathbf{o}, \mathbf{a}, \mathbf{r}, \mathbf{o}' \rangle$ into memory $\mathbf{D}$;
    Randomly sample a minibatch from $\mathbf{D}$;
    for *UAV* $i \leftarrow 1$ *to* N **do**
      Update the critic network according to Equation (23) and (24);
      if f_d **then**
        Update the actor network according to Equation (25);
        Update the target actor network according to Equation (27);
      Update the target critic network according to Equation (26);

IV. 实验

A. Experimental Setup

环境被限制在一个边界为[−1, 1]的正方形区域内。每架无人机具有相同的配置：机身半径为0.05单位，探测半径为0.6单位，覆盖半径为0.15单位。仿真时间步长为0.03秒，无人机最大速度为每时间步0.05单位。目标和障碍物以随机方向和随机速度移动，目标的最大速度设为每时间步0.02单位，障碍物的最大速度设为每时间步0.01单位。为保持环境复杂度的一致性，一旦目标被无人机覆盖，便会从环境中移除，并在另一位置随机生成新目标。

B. Simulation Results Analysis

为了评估我们方法（SDA-MATD3）的性能，我们将其与三种基线方法进行比较：标准MATD3、基于多智能体注意力批评的MATD3（MAAC-MATD3）[22]以及基于全局与局部注意力的MATD3（GLA-MATD3）[23]。图4展示了这两种基于注意力的基线方法的网络结构。每种方法均训练100,000个回合，每个回合包含500个时间步。

图5展示了在三种不同环境设置下的学习曲线。与MATD3基线相比，引入注意力模块显著提升了无人机的覆盖性能。我们的方法始终优于

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

表 I 不同方法的性能指标

Method	Scenario	Reward	Targets	Col-UAVs	Col-Obs
MATD3	4U-6O-12T	135.76 ± 23.96	16.79 ± 2.80	0.16 ± 0.05	0.62 ± 0.04
	6U-6O-15T	32.02 ± 29.51	7.13 ± 3.01	1.31 ± 0.10	0.95 ± 0.08
	8U-6O-18T	40.01 ± 16.37	6.88 ± 3.61	2.82 ± 0.14	1.69 ± 0.12
MAAC-MATD3	4U-6O-12T	139.05 ± 19.37	17.23 ± 1.61	0.17 ± 0.03	0.59 ± 0.03
	6U-6O-15T	109.06 ± 23.86	13.56 ± 2.64	0.58 ± 0.06	$\mathbf{0.63 \pm 0.08}$
	8U-6O-18T	79.54 ± 23.20	10.86 ± 2.97	1.78 ± 0.18	$\mathbf{1.15 \pm 0.17}$
GLA-MATD3	4U-6O-12T	139.95 ± 25.96	18.06 ± 2.36	0.14 ± 0.03	$\mathbf{0.42 \pm 0.03}$
	6U-6O-15T	138.10 ± 18.39	16.83 ± 1.72	0.43 ± 0.04	0.80 ± 0.09
	8U-6O-18T	94.26 ± 18.68	13.08 ± 2.84	0.86 ± 0.09	1.35 ± 0.14
SDA-MATD3	4U-6O-12T	$\mathbf{189.35 \pm 20.30}$	$\mathbf{21.78 \pm 1.69}$	$\mathbf{0.13 \pm 0.02}$	0.55 ± 0.05
	6U-6O-15T	$\mathbf{211.90 \pm 28.31}$	$\mathbf{24.95 \pm 3.07}$	$\mathbf{0.28 \pm 0.04}$	0.83 ± 0.06
	8U-6O-18T	$\mathbf{195.73 \pm 25.01}$	$\mathbf{22.62 \pm 2.58}$	$\mathbf{0.79 \pm 0.08}$	1.46 ± 0.16

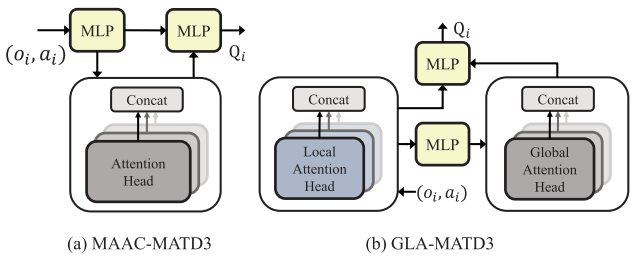

(a) MAAC-MATD3 (b) GLA-MATD3

图4. MAAC-MATD3和GLA-MATD3的网络架构。MAAC-MATD3采用MHA处理各智能体的观测信息。GLA-MATD3在MAAC-MATD3基础上进一步引入内部注意力模块，在智能体间通信前提取每个智能体局部观测中的重要特征。

基于累积奖励和目标覆盖率的三个基线。这些性能优势在更复杂的环境中尤为显著。这凸显了具有动态稀疏性调整的EAM的有效性，它增强了局部信息提取能力，并提升了对动态和复杂场景的适应性。

为了进一步评估这四种方法在分布式执行中的性能，我们对前述场景进行了500轮测试。评估指标包括：1) 每轮每架无人机的平均奖励；2) 每轮每架无人机覆盖的目标平均数量；3) 每轮无人机之间的碰撞损伤次数；4) 每轮无人机与障碍物碰撞损伤次数。表I总结了这四种方法在三个场景（记为4U-6O-12T、6U-6O-15T和8U-6O-18T）下各项性能指标的均值和标准差。表I中加粗数字表示最优值。

从表I可见，我们的方法在平均奖励和目标覆盖率方面具有明显优势。在最复杂的场景（8U-6O-18T）中，其平均目标覆盖率分别达到三种基线方法的3.29倍、2.08倍和1.73倍，平均奖励分别达到4.89倍、2.46倍和2.08倍。在最简单的场景（4U-6O-12T）中，各方法的碰撞率相近。然而，在更复杂的场景（6U-6O-15T和8U-6O-18T）中，我们的方法实现了最低的无人机间碰撞率（0.28和0.79），展现出更优的协同能力。由于障碍物的随机运动，无人机与障碍物的碰撞率较高，但我们的性能与基线方法相当。值得注意的是，在地图尺寸固定的情况下，随着环境复杂度的增加，

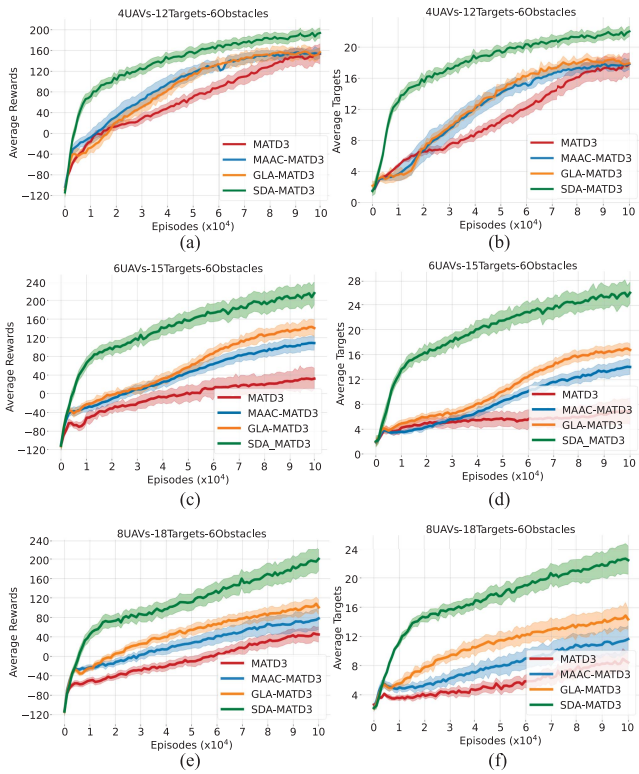

图5. 三种方法在三个场景下的平均奖励函数和平均覆盖目标数量对比（SDA-MATD3为我们的方法）。

由于物理拥塞和协调难度增加，三种基线方法的指标迅速下降，而我们的方法仅出现轻微波动，表明其对复杂性增加具有较强的鲁棒性。

C. Attention Analysis

为评估EAM学习注意力分布的能力以及动态稀疏性调整在训练过程中过滤不相关实体的作用，我们在包含8架无人机、18个目标和6个障碍物的场景中，分析了EAM在不同训练阶段的注意力权重。图6展示了训练30,000轮和100,000轮后，每架无人机对其他无人机、障碍物和目标的注意力权重分布。

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

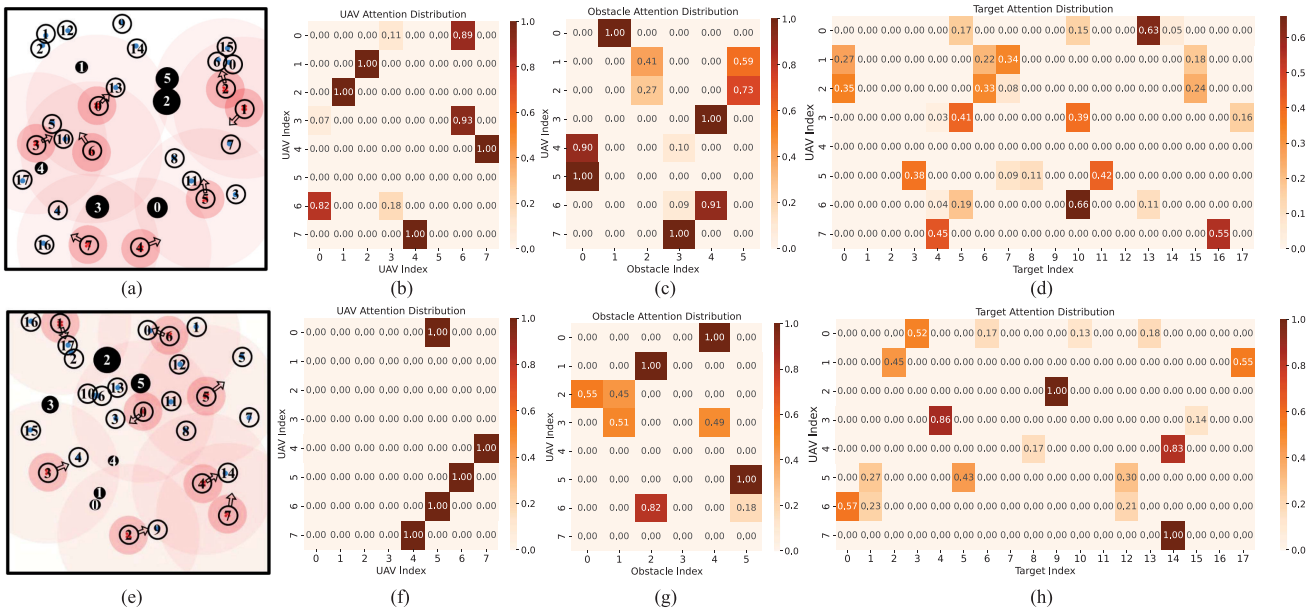

图6. 在30,000和100,000次训练回合后EAM中的注意力权重分布。(a)和(e)用红色表示无人机，蓝色表示目标，黑色表示障碍物。(b)-(d)和(f)-(h)展示了无人机分配给不同实体类别（其他无人机、障碍物和目标）的注意力权重。纵轴表示无人机索引，横轴表示当前实体类别的索引。

图6(a)–(d)和图6(e)–(h)分别展示了经过30,000次和100,000次训练后，各无人机对其他无人机、障碍物和目标的注意力权重分布。总体而言，无人机倾向于为距离更近、角度偏差更小的实体分配更高的权重。经过30,000次训练后，无人机能够正确区分不同实体的相对重要性，但对不相关实体的筛选仍不足。经过100,000次训练后，当λ达到最大值1时，无人机不仅能有效区分实体的重要性，还能将不相关实体的注意力权重稀疏化为零。

以无人机 U_0 为例，经过 30,000 次训练后，如图 6(d) 所示，尽管 U_0 已学会将最大权重 0.63 分配给目标 G_{13}，但对较不相关目标（如 G_{14}）的关注尚未完全稀疏化为零。经过 100,000 次训练后，如图 6(e) 所示，U_0 检测到目标 G_3、G_6、G_8、G_{10}、G_{11}、G_{12} 和 G_{13}。考虑到其速度方向和相对距离，对 G_8、G_{11} 和 G_{12} 的注意力权重被稀疏化为零，而 G_3 获得最高权重 0.52。对于障碍物注意力，如图 6(g) 所示，T_2 和 T_5 的权重也被稀疏化为零，而位于速度方向上的 T_4 获得最高注意力。

D. Ablation Studies

为评估动态稀疏度调整的有效性及各模块的贡献，我们将SDA-MATD3与三种消融变体进行比较：仅使用Softmax的SDA-MATD3（无稀疏）、完全采用Sparsemax的SDA-MATD3（全稀疏），以及不含IAM的EAM-only-MATD3。图7展示了三种场景下的学习曲线。我们未移除EAM的消融实验，因为该变体等同于基线MAAC-MATD3。

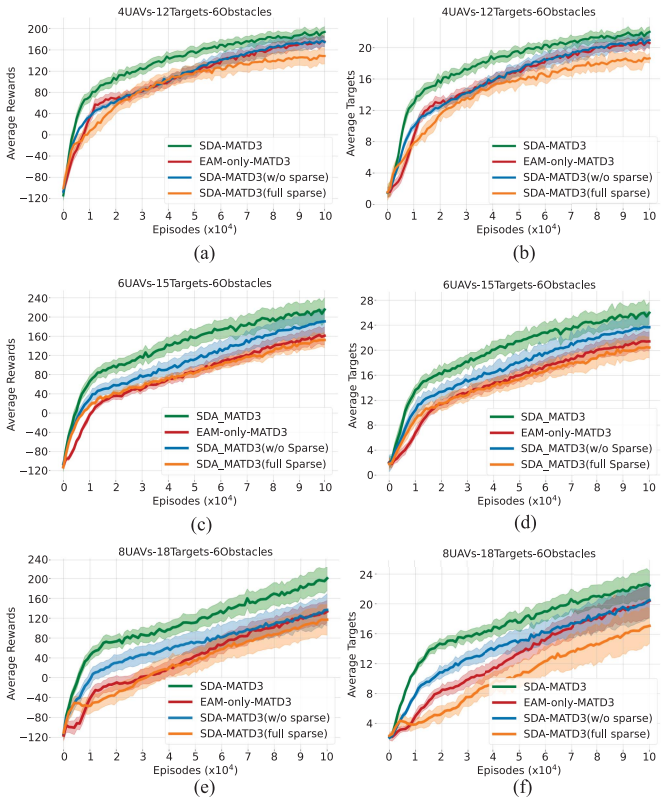

图7. 消融研究中三种场景下平均奖励和平均覆盖目标数的比较。

比较结果表明，与仅使用Softmax函数或Sparsemax函数的基线相比，引入动态稀疏性调整机制提升了无人机覆盖性能。在训练初期

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.

在初始阶段，Softmax均匀分配注意力权重，防止过早忽视已观测实体。随着训练进行，UAVs学习不同实体的相对重要性，稀疏控制参数逐渐增大，使EAM通过稀疏化不相关实体来聚焦于关键实体。动态稀疏调整的优势在复杂场景中尤为显著。此外，消融研究突显了IAM的贡献：移除IAM（仅EAM-MATD3）会削弱智能体间的协作，导致覆盖效率下降。完整的SDA-MATD3始终取得最佳性能，证实了IAM与EAM的互补性及其在提升协同UAV效率中的核心作用。

V. 结论

在本文中，我们提出一种基于MADRL的双注意力学习方法，结合稀疏优化，以应对复杂动态环境中的协同覆盖任务。具体而言，我们引入了一种层次化注意力机制，以处理局部观测中的不同实体集，并融合了动态稀疏调整机制。该机制使智能体能够动态分配注意力权重至不同实体，并自主稀疏化这些权重，从而提升训练效率与覆盖性能。通过在不同复杂度场景下的仿真，验证了所提方法的有效性与泛化能力。尽管结果令人鼓舞，但当前的稀疏控制参数采用简单的线性调度，可能并非最优，有望通过更具自适应性或理论指导的调整策略进一步优化。在未来的工作中，我们将探索MADRL在多无人机系统中的实际部署与应用。

参考文献

[1] J. Chen, Y. Zhang, L. Wu, T. You, 和 X. Ning, “一种基于自适应聚类的异构无人机自动路径规划算法,” *IEEE Trans. Intell. Transp. Syst.*, 卷 23, 期 9, 页 16842–16853, 2022 年 9 月。[2] S. Zhao, J. Zheng, F. Yi, X. Wang, 和 Z. Zuo, “具有输入饱和的固定翼无人机指数预定义时间轨迹跟踪控制,” *IEEE Trans. Aerosp. Electron. Syst.*, 卷 60, 期 5, 页 6406–6419, 2024 年 10 月。[3] J. Yang, Y. Hu, Z. Yu, F. Chen, 和 X. Xu, “深度协调与扩展：低空空域中无人机的分布式机载冲突解决,” *IEEE Trans. Intell. Veh.*, 卷 9, 期 1, 页 2780–2793, 2024 年 1 月。[4] Y. Bai, H. Zhao, X. Zhang, Z. Chang, R. Jäntti, 和 K. Yang, “面向自主多无人机无线网络：基于强化学习方法的综述,” *IEEE Commun. Surveys Tuts.*, 卷 25, 期 4, 页 3038–3067, 2023 年第四季度。[5] K. Kumar 和 N. Kumar, “面向区域覆盖的无人机路径规划：系统性综述,” *Phys. Commun.*, 卷 59, 2023 年, 文章编号 102073。

[6] M. Sherman, S. Shao, X. Sun, J. Zheng, “Counter UAV swarms: Challenges, considerations, and future directions in UAV warfare,” *IEEE Wireless Commun.*, vol. 32, no. 1, pp. 190–196, Feb. 2025. [7] Y. Huang, Y. Wang, Z. Li, H. Zhang, C. Zhang, “A hierarchical multi robot coverage strategy for large maps with reinforcement learning and dense segmented Siamese network,” *IEEE Robot. Automat. Lett.*, vol. 10, no. 1, pp. 444–451, Jan. 2025. [8] A. Mavrommati, E. Tzorakoleftherakis, I. Abraham, T. D. Murphey, “Real-time area coverage and target localization using receding-horizon ergodic exploration,” *IEEE Trans. Robot.*, vol. 34, no. 1, pp. 62–80, Feb. 2018. [9] L. Kraemer, B. Banerjee, “Multi-agent reinforcement learning as a rehearsal for decentralized planning,” *Neurocomputing*, vol. 190, pp. 82–94, 2016. [10] F. A. Oliehoek, M. T. Spaan, N. Vlassis, “Optimal and approximate Q-value functions for decentralized pomdps,” *J. Artif. Intell. Res.*, vol. 32, pp. 289–353, 2008. [11] Y. Cao, T. Hou, Y. Wang, X. Yi, G. Sartoretti, “ARiADNE: A reinforcement learning approach using attention-based deep networks for exploration,” in *Proc. 2023 IEEE Int. Conf. Robot. Automat.*, 2023, pp. 10219–10225. [12] R. Wang, D. Zhao, A. Gupte, B.-C. Min, “Initial task allocation in multi-human multi-robot teams: An attention-enhanced hierarchical reinforcement learning approach,” *IEEE Robot. Automat. Lett.*, vol. 9, no. 4, pp. 3451–3458, Apr. 2024. [13] L. Chen et al., “Transformer-based imitative reinforcement learning for multirobot path planning,” *IEEE Trans. Ind. Informat.*, vol. 19, no. 10, pp. 10233–10243, Oct. 2023. [14] S. Nayak, K. Choi, W. Ding, S. Dolan, K. Gopalakrishnan, H. Balakrishnan, “Scalable multi-agent reinforcement learning through intelligent information aggregation,” in *Proc. Int. Conf. Mach. Learn.*, 2023, pp. 25817–25833. [15] S. Wu, Z. Pu, T. Qiu, J. Yi, T. Zhang, “Deep-reinforcement-learning-based multitarget coverage with connectivity guaranteed,” *IEEE Trans. Ind. Informat.*, vol. 19, no. 1, pp. 121–132, Jan. 2023. [16] J. Li, H. Ma, Z. Zhang, J. Li, M. Tomizuka, “Spatio-temporal graph dual-attention network for multi-agent prediction and tracking,” *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 8, pp. 10556–10569, Aug. 2022. [17] H. Zhang, J. Chen, J. Cheng, Y. Li, S. X. Yang, W. Zhang, “Nowhere to go: Benchmarking multirobot collaboration in target trapping environment,” *IEEE Trans. Ind. Electron.*, vol. 71, no. 11, pp. 14430–14439, Nov. 2024. [18] J. Han, Y. Zhu, J. Yang, “A deep reinforcement learning method for collision avoidance with dense speed-constrained multi-UAV,” *IEEE Robot. Automat. Lett.*, vol. 10, no. 3, pp. 2152–2159, Mar. 2025. [19] Y. Niu, R. R. Paleja, M. C. Gombolay, “Multi-agent graph-attention communication and teaming,” in *Proc. 20th Int. Conf. Auton. Agents MultiAgent Syst.*, 2021, pp. 964–973. [20] C. Zhu, M. Dastani, S. Wang, “A survey of multi-agent deep reinforcement learning with communication,” *Auton. Agents Multi-Agent Syst.*, vol. 38, no. 1, 2024, Art. no. 4. [21] X. Li, G. Yang, D. Zhang, J. Tao, “APC: Predict global representation from local observation in multi-agent reinforcement learning,” in *Proc. 2024 Int. Joint Conf. Neural Netw.*, 2024, pp. 1–8. [22] S. Iqbal, F. Sha, “Actor-attention-critic for multi-agent reinforcement learning,” in *Proc. Int. Conf. Mach. Learn.*, 2019, pp. 2961–2970. [23] J. Chen et al., “Global-and-local attention-based reinforcement learning for cooperative behaviour control of multiple UAVs,” *IEEE Trans. Veh. Technol.*, vol. 73, no. 3, pp. 4194–4206, Mar. 2024. [24] K. Hu et al., “An overview: Attention mechanisms in multi-agent reinforcement learning,” *Neurocomputing*, vol. 598, 2024, Art. no. 128015. [25] A. Martins, R. Astudillo, “From softmax to sparsemax: A sparse model of attention and multi-label classification,” in *Proc. Int. Conf. Mach. Learn.*, 2016, pp. 1614–1623. [26] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbell, I. Mordatch, “Multi-agent actor-critic for mixed cooperative-competitive environments,” in *Proc. Adv. Neural Inf. Process. Syst.*, 2017, pp. 6379–6390.

Authorized licensed use limited to: Zhejiang University of Technology. Downloaded on March 03,2026 at 01:16:56 UTC from IEEE Xplore. Restrictions apply.